

ÉVALUATION FINALE

IA for Tech

Version 1.1 du 08/10/2026

Nom, prénom	
Date de session	

L'évaluation finale comporte deux parties : **Partie A – QCM (10 questions, /10)**, une seule tentative, passée lors de la dernière séance ; **Partie B – projet final (/10)** : l'application agentique complète (RAG + MCP + evals) construite pendant la formation, déployée et évaluée par le formateur lors des démonstrations individuelles (module 6). **Objectifs atteints à partir de 12/20**. Les résultats sont reportés sur l'attestation de fin de formation.

Partie A – QCM (10 questions)

1. La fenêtre de contexte d'un modèle limite...

- ☐ a. Le nombre d'utilisateurs simultanés
- ☐ b. La quantité de tokens que le modèle peut traiter dans un échange
- ☐ c. La durée d'une conversation en minutes
- ☐ d. Le nombre de langues supportées

2. Quand privilégier un petit modèle ?

- ☐ a. Jamais : le plus gros modèle est toujours meilleur
- ☐ b. Pour les raisonnements les plus complexes
- ☐ c. Pour les tâches simples à fort volume où latence et coût priment
- ☐ d. Uniquement en environnement de test

3. En production, face aux erreurs de rate limit (429), la bonne pratique est...

- ☐ a. Réessayer immédiatement en boucle
- ☐ b. Ignorer l'erreur et rendre une réponse vide
- ☐ c. Changer de fournisseur à chaque erreur
- ☐ d. Des retries avec backoff exponentiel et une gestion de quota

4. Le tool use / function calling permet...

- ☐ a. Au modèle de demander l'exécution de fonctions définies par le développeur
- ☐ b. Au modèle de modifier son propre code
- ☐ c. De réduire le coût des appels
- ☐ d. De supprimer les hallucinations

5. Dans un pipeline RAG, les embeddings servent à...

- ☐ a. Chiffrer les documents
- ☐ b. Représenter les textes en vecteurs pour la recherche sémantique
- ☐ c. Compresser la base de données
- ☐ d. Générer les réponses finales

6. Le RAG est préférable au fine-tuning quand...

- ☐ a. On veut changer le style de réponse du modèle
- ☐ b. Le budget GPU est illimité
- ☐ c. Les connaissances changent souvent et doivent être sourcées
- ☐ d. Les données tiennent dans le prompt

7. MCP (Model Context Protocol) est...

- ☐ a. Un format de fichier de prompts
- ☐ b. Un protocole standard pour connecter modèles, outils et sources de données
- ☐ c. Une base de données vectorielle
- ☐ d. Un modèle open-source

8. Le sandboxing d'un agent qui exécute du code sert à...

- ☐ a. Accélérer l'exécution
- ☐ b. Réduire la consommation de tokens
- ☐ c. Améliorer la qualité du code généré
- ☐ d. Isoler l'exécution pour protéger le système hôte

9. Un « LLM-as-judge » est...

- ☐ a. Un modèle qui évalue les sorties d'un autre selon des critères définis
- ☐ b. Un tribunal d'arbitrage pour litiges IA
- ☐ c. Un modèle spécialisé en droit
- ☐ d. Un composant qui bloque les requêtes interdites

10. La prompt injection est...

- ☐ a. Une technique d'optimisation des prompts
- ☐ b. Une manipulation du modèle via du contenu malveillant dans le contexte, à contrer par guardrails et moindre privilège
- ☐ c. Un bug d'affichage des conversations
- ☐ d. Une méthode de compression du contexte

Partie B — Projet final (évalué par le formateur, /10)

Critère observable	Points	Obtenu
Pipeline RAG fonctionnel (ingestion, retrieval, réponses sourcées)	2	
Tool use et/ou serveur MCP intégré à l'application	2	

Evals en place (dataset de test, métriques, LLM-as-judge le cas échéant)	2	
Sécurité : guardrails, gestion des entrées/sorties, moindre privilège	2	
Déploiement effectif + observabilité (tracing / logging)	2	

Grille de correction — Partie A (réservée à l'organisme)

Question	Bonne réponse	Objectif
1	b. La quantité de tokens traitables dans un échange	1
2	c. Tâches simples à fort volume (latence, coût)	1
3	d. Retries avec backoff exponentiel et gestion de quota	2
4	a. Demander l'exécution de fonctions définies par le développeur	2
5	b. Représenter les textes en vecteurs (recherche sémantique)	3
6	c. Connaissances changeantes et sourcées	3
7	b. Protocole standard modèles ↔ outils et données	4
8	d. Isoler l'exécution pour protéger le système hôte	4
9	a. Un modèle qui évalue les sorties d'un autre	5
10	b. Manipulation via contenu malveillant, contrée par guardrails	5

Total : QCM /10 + projet final /10 = note /20. Objectifs de la formation atteints à partir de **12/20 (60 %)**.
Résultats reportés sur l'attestation de fin de formation.