

TEST DE POSITIONNEMENT

IA for Tech

Version 1.1 du 08/10/2026

Nom, prénom

Date

Ce test situe précisément votre **niveau d'ingénierie LLM** (APIs, RAG, agents, MCP, evals, supervision) et vérifie les **prérequis de programmation**, afin d'adapter l'animation à votre niveau. **Il n'est pas éliminatoire**. Il est passé en ligne avant l'entrée en formation ; la correction est réalisée par l'organisme.

A. Auto-évaluation

Où en êtes-vous de l'intégration de LLM dans vos projets ? (une seule réponse)

- ☐ Débutant (je n'ai jamais intégré de LLM dans du code)
- ☐ Notions (quelques appels d'API ou prototypes)
- ☐ Confirmé (fonctionnalités LLM en production : RAG, agents ou evals)

B. Prérequis — Programmation

1. Une API REST renvoie généralement ses données au format...

- ☐ a. PDF
- ☐ b. JSON
- ☐ c. CSV uniquement
- ☐ d. Binaire propriétaire

2. Une variable d'environnement sert à...

- ☐ a. Accélérer le processeur
- ☐ b. Configurer une application sans modifier son code (secrets, URLs)
- ☐ c. Stocker les logs
- ☐ d. Compiler le programme

3. La commande git commit sert à...

- ☐ a. Envoyer le code au serveur distant
- ☐ b. Supprimer des fichiers
- ☐ c. Enregistrer un instantané des modifications dans l'historique
- ☐ d. Installer les dépendances

C. Ingénierie LLM

4. Un LLM génère du texte en...

- ☐ a. Cherchant dans une base de réponses
- ☐ b. Exécutant des règles écrites à la main
- ☐ c. Copiant des pages web
- ☐ d. Prédissant les tokens les plus probables

5. Le paramètre « temperature » contrôle...

- ☐ a. La vitesse de réponse
- ☐ b. Le degré d'aléa / créativité de la génération
- ☐ c. Le coût de l'appel
- ☐ d. La taille du contexte

6. La fenêtre de contexte d'un LLM désigne...

- ☐ a. La durée maximale d'une session
- ☐ b. La quantité de tokens que le modèle peut prendre en compte dans un échange
- ☐ c. Le nombre d'utilisateurs simultanés
- ☐ d. La mémoire disque du serveur d'inférence

D. RAG

7. Le RAG consiste à...

- ☐ a. Réentraîner le modèle sur ses données
- ☐ b. Compresser le contexte
- ☐ c. Fournir au modèle des documents récupérés pour ancrer ses réponses
- ☐ d. Chiffrer les prompts

8. Dans un pipeline RAG, le « chunking » consiste à...

- ☐ a. Compresser le modèle
- ☐ b. Découper les documents en segments avant de calculer leurs embeddings
- ☐ c. Supprimer les doublons de la base
- ☐ d. Chiffrer les requêtes

9. Après une recherche hybride (vecteurs + mots-clés), le reranking sert à...

- ☐ a. Réordonner les passages récupérés selon leur pertinence réelle pour la requête
- ☐ b. Mettre en cache les réponses
- ☐ c. Réduire la facture d'API
- ☐ d. Traduire les documents récupérés

E. Systèmes agentiques

10. Dans une boucle agentique de type ReAct, le modèle...

- ☐ a. Génère la réponse finale en un seul appel
- ☐ b. Alterne raisonnement et appels d'outils jusqu'à atteindre l'objectif
- ☐ c. Réentraîne ses poids à chaque étape
- ☐ d. Délègue toutes les décisions à un humain

11. MCP (Model Context Protocol) sert à...

- ☐ a. Compresser les prompts
- ☐ b. Standardiser l'accès des modèles à des outils et sources de données externes
- ☐ c. Héberger des modèles open source
- ☐ d. Mesurer la latence réseau

F. Fiabilité et supervision

12. La « prompt injection » est...

- ☐ a. Une technique d'optimisation des prompts
- ☐ b. Une attaque où un contenu externe détourne les instructions du système
- ☐ c. Un bug du tokenizer
- ☐ d. Une méthode de fine-tuning

13. Une eval « LLM-as-judge » consiste à...

- ☐ a. Demander aux utilisateurs de noter l'application
- ☐ b. Faire noter les sorties du système par un modèle selon une grille définie
- ☐ c. Mesurer uniquement la latence
- ☐ d. Comparer les prix des fournisseurs

14. Pour superviser des agents IA en production, le signal le plus utile est...

- ☐ a. Le nombre de lignes de code
- ☐ b. Les traces d'exécution (étapes, outils appelés, tokens, coûts) avec alertes sur les échecs
- ☐ c. La fréquence des déploiements
- ☐ d. Le nombre de commits par jour

G. Votre stack (facultatif)

Décrivez votre stack habituelle et un cas d'usage IA que vous aimeriez construire.

Connaissez-vous l'un de ces termes ? (cochez)

- ☐ Embeddings
- ☐ Hybrid search / reranking

- ☐ Tool use / function calling
- ☐ RAG agentique
- ☐ MCP
- ☐ Evals / LLM-as-judge
- ☐ Guardrails / prompt injection
- ☐ Observabilité des agents

H. Vos attentes

Avez-vous un cas d'usage ou un objectif précis pour cette formation ?

Grille de correction (réservée à l'organisme)

Question	Bonne réponse	Notion
1	b. JSON	Prérequis — APIs
2	b. Configurer sans modifier le code (secrets, URLs)	Prérequis — configuration / secrets
3	c. Enregistrer un instantané dans l'historique	Prérequis — Git
4	d. Prédissant les tokens les plus probables	Ingénierie LLM — principe des LLM
5	b. Le degré d'aléa / créativité	Ingénierie LLM — paramètres d'inférence
6	b. La quantité de tokens prise en compte dans un échange	Ingénierie LLM — fenêtre de contexte
7	c. Fournir des documents récupérés au modèle	RAG — principe
8	b. Découper les documents en segments avant les embeddings	RAG — chunking
9	a. Réordonner les passages selon leur pertinence réelle	RAG — hybrid search / reranking
10	b. Alterne raisonnement et appels d'outils jusqu'à l'objectif	Systèmes agentiques — boucle ReAct
11	b. Standardiser l'accès des modèles aux outils et données externes	Systèmes agentiques — MCP
12	b. Une attaque où un contenu externe détourne les instructions	Fiabilité — prompt injection
13	b. Faire noter les sorties par un modèle selon une grille définie	Fiabilité — evals / LLM-as-judge
14	b. Les traces d'exécution (étapes, outils, tokens, coûts) avec alertes	Supervision — observabilité des agents

Note sur 14 — les questions 1 à 3 vérifient les prérequis de programmation ; les questions 4 à 14 situent précisément le niveau d'ingénierie LLM de départ (fondamentaux, RAG, agents et MCP, fiabilité et supervision). Le résultat, combiné à l'auto-évaluation, aux termes connus et à la description de la stack, sert à adapter le rythme et les exemples de la session. Le test n'est pas éliminatoire.